

$$x_1 = y_2$$

$$\begin{bmatrix} 1 & 0 \\ 1 & 0 \\ 1 & 0 \\ 1 & 0 \end{bmatrix}$$

$$x_{n \times 2}$$

$$\begin{bmatrix} -40 & 200 & 150 \\ 0.25 & 0.1 & 0.1 \end{bmatrix}$$

$$[2] \times 3$$

$$y_2$$

## Logistic Regression

→ temos dados num training set

→ quando add 1 dado los combinamos e obtemos a hipótese de classificação

→ Precisamos de  $0 \leq \text{hipótese} \leq 1$

A Função Sigmoid para samples  $0 \leq \text{Sigmoid} \leq 1$

$$h(\theta; x) = \theta^T x$$

$$g(x) = g(\theta^T x) = \frac{1}{1 + e^{-x}}$$

$$\frac{1}{1 + e^{-\theta^T x}}$$

↓  
Próximo ou não próximo ao exemplo  $\begin{cases} 0 - \text{Não} \\ 1 - \text{Sim} \end{cases}$

$$\text{Se } h(x) = 0.7$$

→ valor de Habilidade

Estimamos  $P(y=1)$  por input:  $P(y=1 | x; \theta) = 0.7$

## Decision Boundary = Linear Regression

Supor  $h(\theta; x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$

$$\theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$$

$$-3 + x_1 + x_2 \geq 0$$

$$x_1 + x_2 \geq 3$$

$$0 + 3 = 3 \checkmark$$


$$3 + 0 = 3$$

$$4 + 1 = 5$$

$$-3 + (1) + (1) \geq 0 \text{ (sim)}$$

$$-3 + 2 \geq 0 \text{ (sim)}$$

$$-1 \geq 0 \text{ (não)}$$



Forma 3? → N podemos usar L.R para termos mais mínimos quadrados

$$\begin{cases} -\log(h(\theta; x)) & y=1 \\ -\log(1-h(\theta; x)) & y=0 \end{cases}$$

$$-\log(1-h(\theta; x)) \quad y=0$$

$$\text{Juntamos as Formulas} \quad -y \log(h(\theta; x)) - (1-y) \log(1-h(\theta; x)) = \frac{1}{m} \sum_{i=1}^m \log(h(\theta; x_i)^y (1-h(\theta; x_i))^{1-y})$$

## Minimizar

$$\theta_3 = \theta_3 = \alpha \cdot \frac{\partial}{\partial \theta_3} J(\theta)$$

$$= \frac{1}{m} \sum_{i=1}^m (h(\theta; x_i) - y_i) x_i$$

$$\frac{1}{1 + e^{-\theta^T x}}$$

$$\Rightarrow \theta_3 = \theta_3 -$$

grad

thet

$$\checkmark \text{Sum}(\text{Sigmoid}(x + \theta_0) - y)$$

fun inverte (1) → Optimizar 3 Sim. repetidas

$$\text{grad} = \frac{1}{m} X^T (\text{Sigmoid}(x) - y)$$